به نام خدا

گزارشکار پروژه‌ی کامپایلر – فاز اول

اصول طراحی کامپایلر

استاد: آرش شفیعی

اعضای گروه:

محمدکاظم هرندی (۴۰۰۳۶۲۳۰۳۹)

مسعود محمدزاده (۴۰۱۲۳۶۳۱۴۷)

بهار ۱۴۰۳

https://github.com/mohammadkahr/Two-M-Compiler.git

فهرست

مرور کلی از کد:

۱.ثابت‌هایی برای کلیدواژه‌ها، عملگرها و علائم تعریف شده‌اند.

۲.یک نگاشت(Mapping) بین توکن‌ها و نام‌های متناظر آنها تعریف شده است.

۳.این کد شامل توابعی برای شناسایی انواع مختلف توکن‌ها است:

- **کلیدواژه‌ها** Keywords
- **عملگرها** Operators
- **شناسه‌ها** Identifiers
- **علائم** Delimiters
- **مقادیر عددی (اعشاری و شانزده‌گانه)** Numeric literals (decimal and hexadecimal)
- **مقادیر رشته‌ای** String literals
- **توضیحات** Comments
- **فضاهای خالی** Whitespace

۴.یک کلاس به نام Token **تعریف شده است که توکن‌ها را با ویژگی‌هایی مانند نام، شماره خط، مقدار و تعداد نمایش می‌دهد.**

۵.تابع tokenizer() **تابع اصلی است که مسئول تولید توکن‌ها است. این تابع هر خط را خوانده، هر خط را توکن‌بندی کرده و بر اساس قوانین تعریف شده در کد، توکن‌ها را تولید می‌کند.**

۶.توکن‌های تولید شده در یک فایل خروجی (output1.txt) ذخیره می‌شوند و توکن‌های فضای خالی حذف می‌شوند.

پیاده سازی توابع با استفاده از (state machine)

در اینجا به توضیح درباره پیاده سازی چندتا از تابع هایی که با استفاده از (state machine) **پیاده سازی شده اند می پردازیم.**

-پیاده سازی تابع برای شناسایی کامنت ها:

ابتدا عبارت منظم مربوطه را نوشتیم: **r'^\/{2}.*$**

۱-۱-توضیحات عبارت منظم:

این عبارت منظم به صورت زیر توضیح داده می‌شود:

`^`: این نشان دهنده شروع رشته است.

`\/{2}`: این بخش با دو علامت `/` مطابقت می‌کند. به علامت `/` اضافه شده است و به دلیل اینکه `/` نیز یک کاراکتر متخصص در عبارت منظم است، باید با `\` متناظر شود. `{2}` نشان دهندهٔ این است که علامت `/` دوبار تکرار می‌شود.

`.*`: این الگو با هر کاراکتری که در ادامه دو علامت `/` آمده باشد مطابقت می‌کند. `.` به معنای هر کاراکتری است و `*` به معنای صفر یا بیشتر تکرار آن است.

`$`: این نشان دهنده پایان رشته است.

بنابراین، به طور کلی، این الگو با هر رشته‌ای که با دو علامت `/` شروع شود و سپس دنباله‌ای از هر کاراکتر دیگری داشته باشد تا پایان خط مطابقت می‌کند.

۱-۲-تبدیل عبارت منظم به دیاگرام حالت:

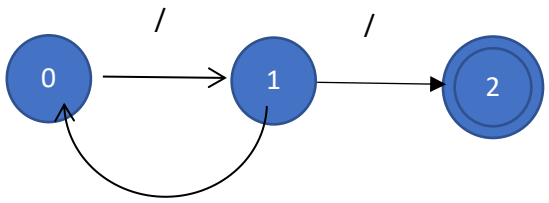

Others

۱-۳-تبدیل دیاگرام حالت به کد:

در اینجا، وضعیت state **با استفاده از متغیر** state **برای نشان دادن وضعیت فعلی ماشین حالتی استفاده می‌شود. بر اساس وضعیت فعلی و ورودی، ما به وضعیت جدید منتقل می‌شویم تا در نهایت تشخیص دهیم که آیا رشته ورودی یک توضیحات است یا خیر.**

```python
def comment(token: str):
    state = 0
    for char in token:
        if state == 0:
            if char == "/":
                state = 1
        elif state == 1:
            if char == "/":
                state = 2
        elif state == 2:
            return True
    return False
```

-پیاده سازی تابع برای شناسایی شناسه ها:

با استفاده از عبارت منظم: [_a-zA-Z][_a-zA-Z0-9]

۱-۱-توضیحات عبارت منظم:

[_a-zA-Z]: **این بخش از عبارت، یک حرف از الفبای انگلیسی (بزرگ یا کوچک) یا یک آندرلاین (_) را متناظر می‌کند. در اصطلاحات متنی، این بخش به عنوان اولین حرف شناسه استفاده می‌شود و حرف اول شناسه باید یک حرف از الفبا یا آندرلاین باشد.**

[_a-zA-Z0-9]: **این بخش نیز به عنوان حرف دوم و بعدی شناسه استفاده می‌شود. این حرف می‌تواند یک حرف از الفبا (بزرگ یا کوچک)، یک عدد (۰ تا ۹) یا آندرلاین (_) باشد. به این ترتیب، شناسه می‌تواند شامل هر یک از این حروف و اعداد باشد.**

۱-۲-تبدیل عبارت منظم به دیاگرام حالت:

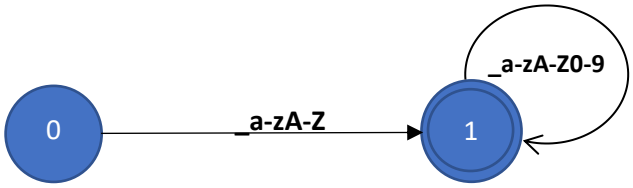

۱-۳-تبدیل دیاگرام حالت به کد:

```
def identifier(token: str):
    state = 0
    temp = get_token_until_delimiter(token)
    if len(temp) == 0:
        return False, None

    for char in temp:
        if state == 0:
            if char == '_' or char.isalpha():
                state = 1
            else:
                return False, None
        elif state == 1:
            if char.isalnum() or char == '_':
                continue
            else:
                return False, None

    return state == 1, temp if state == 1 else None
```

-پیاده سازی تابع برای شناسایی اعداد باینری:

عبارت منظم رو به رو را داریم:

^ 0b[01]*$

^: این علامت نشان دهنده شروع رشته است، بنابراین رشته باید با الگوی تطابق داشته باشد که از اینجا شروع می‌شود.

0b: این بخش از الگو یک الف تطبیق می‌یابد که در اینجا به "b۰" می‌ختمد. این الف‌ها مشخص می‌کنند که عبارت دیگری به عنوان "باینری" (دودویی) شناخته می‌شود.

[01]*: این قسمت الگو به هر تعداد تکرار از اعداد دودویی (۰ و ۱) تطابق می‌یابد. * یک متعلقه‌ی کوانتیف است که نشان می‌دهد که الگوی قبلی می‌تواند صفر یا بیشتر تکرار شود.

$: این علامت نشان دهنده پایان رشته است، بنابراین رشته باید در اینجا به پایان برسد.

۲-۱-تبدیل عبارت منظم به دیاگرام حالت:

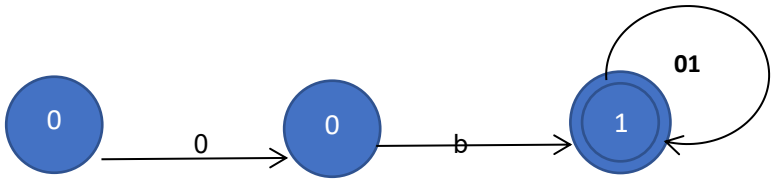

۳-۱-تبدیل دیاگرام حالت به کد:

```
def bin(s: str) -> bool:
    state = 0
    for c in s.lower():
        if state == 0:
            if c == "0":
                state = 1
            else:
                return False
        elif state == 1:
            if c == "b":
                state = 2
            elif c in "01":
                return False
            else:
                return False
        elif state == 2:
            if c not in "01":
                return False
    return True
```

تابع tokenizer :

```
def tokenizer():
    count = 0
    for line in read_file_line("test.txt"):
        count += 1
        start = 0
        while start < len(line):
            if comment(line[start:]):
                yield Token("T_Comment", count, line[start + 2:], count)
                start = len(line)
            elif whitespace(line[start:start + 1]):
                yield Token("T_Whitespace", count, line[start:start + 1],
count)
            elif delimiter(line[start:start + 1])[0]:
```

```
                yield Token(delimiter(line[start:start + 1])[1], count,
line[start:start + 1], count)
            elif litnum(line[start:])[0]:
                _, token_name, number = litnum(line[start:])
                yield Token(token_name, count, number, count)
                start += len(number) - 1
            elif keyword(line[start:])[0]:
                yield Token("T_" + keyword(line[start:])[1], count,
line[start:start + len(keyword(line[start:])[1])],
                            count)
                start += len(keyword(line[start:])[1]) - 1

            elif identifier(line[start:])[0]:
                yield Token("T_ID", count, identifier(line[start:])[1], count)
                start += len(identifier(line[start:])[1]) - 1
            elif operators(line[start:])[0]:
                operator = operators(line[start:])[1]
                token_name = get_token_name(operator)
                yield Token(token_name, count, operator, count)

            elif litstring(line[start:])[0]:
                _, token_name, word = litstring(line[start:])
                yield Token(token_name, count, word, count)
                start += len(word) - 1
            start += 1
```

تابع `tokenizer` **در واقع یک ژنراتور است که به عنوان خروجی توکن‌ها را تولید می‌کند. ورودی این تابع یک فایل متنی به نام** "test.txt" **است. این تابع در هر مرحله یک خط از فایل را می‌خواند و توکن‌های موجود در آن را استخراج می‌کند.**

متغیر `count` **به عنوان شمارنده‌ای برای شمارش خطوط متن ورودی استفاده می‌شود. این متغیر در ابتدا صفر است و با گذشت هر خط جدید از فایل متنی، یک واحد به آن افزوده می‌شود. این متغیر به عنوان شماره خط مورد استفاده برای هر توکن تولید شده است.**

متغیر `start` **به عنوان نشانگری برای موقعیت شروع استخراج توکن در هر خط متنی استفاده می‌شود. این متغیر ابتدا به صفر تنظیم می‌شود و سپس به طول متن خط فعلی متن قرار می‌گیرد تا تمامی توکن‌های موجود در هر خط استخراج شوند.**

در هر مرحله از حلقه while، **توکن جاری استخراج می‌شود. اگر توکنی از نوع کامنت یا فاصله باشد، متغیر** `start` **به آخرین موقعیت ممکن برای شروع توکن بعدی در همان خط تنظیم می‌شود. در غیر این صورت، متغیر** `start` **به سمت رو به جلو حرکت کرده و توکن جاری تا زمانی که به نوعی از نماد یا فاصله می‌رسد، استخراج می‌شود. سپس،**

توکن مربوطه به عنوان خروجی ژنراتور تولید می‌شود و متغیر `start` به عنوان محل شروع توکن بعدی تنظیم می‌شود. این فرآیند تا پایان خط فعلی ادامه پیدا می‌کند.